LABORATUVAR 7 · GENEL SÜRÜM · Mori Seiki NH5000 DCG

# AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad Enis UZUN | Grup Gündüz B | Tarih 06/11/2026

**Kavram — Prediction ≠ Safety:** Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin **dışında** tanımlanmalıdır.
Araçlar: fail-safe · human override · monitoring · confidence threshold · fallback.

Kamera → YZ Modeli → OK / RED → Parametre → Robot

## Görev — üç başarısızlıkta güvenli davranış

1. **Model yanlış sınıflandırdı:** Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

Sistem YZ'nin OK kararına tek başına güvenmez. Bağımsız ikinci kontrol vardır: makinede prob ile ölçüm veya kural tabanlı limit kontrolü; riskli parçada insan onayı (human override). Hatalı OK oranı izlenir (monitoring); eşik aşılırsa hat insan onayına döner. OK çıktısı safety fonksiyonunu (kapı, E-stop, STO) belirlemez; safety YZ'nin dışındadır.

2. **Girdi manipüle edildi:** Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

Fark etme: donmuş/kopya kare, aşırı parlaklık, eksik çerçeve, zaman damgası ve sayaç tutarsızlığı; ikinci sensörle çapraz doğrulama; girdi dağılımı izleme. Şüpheli girdide karar OK sayılmaz (fail-safe): parça RED/karantina, robot ve parametre güncellemesi durur, insana bildirilir, ham veri kanıt olarak saklanır.

3. **Confidence düştü:** Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

Eşik risk bazlı belirlenir ve doğrulama verisiyle ayarlanır; örnek: ≥ %95 otomatik karar, %80–95 insana sor (human override), < %80 dur ve fallback (manuel ölçüm). Yanlış OK, yanlış RED'den pahalıdır; "emin değilim" hiçbir zaman OK sayılmaz.

## Karar tablosu — AI Fail-Safe Decision

| Başarısızlık | Tanımladığınız güvenli davranış (hangi kavramla?) |
|---|---|
| Model yanlış sınıflandırdı | İkinci bağımsız kontrol + insan onayı: prob/limit kontrolü, riskli parçada human override; hatalı OK oranı izlenir. Kavram: human override + monitoring. |
| Girdi manipüle edildi | Şüpheli girdi OK sayılmaz: parça RED/karantina, robot durur, insana bildirilir, ham veri saklanır. Kavram: fail-safe + monitoring (girdi doğrulama). |
| Confidence düştü | Eşik altında otomatik OK yok: insana sor; daha düşükte dur ve fallback (manuel ölçüm). Kavram: confidence threshold + fallback + human override. |

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.